

空気圧人工筋駆動のアームロボットにおける遅れのオンライン推定

M2 吉田瑞希

1 はじめに

低トルクでの制御を実現するために、ロボットの現在の状態に基づいて参照軌道を生成する手法が提案されている [1]. 従来の手法では参照軌道は時間の関数として生成されるため、外乱によってロボットの状態が突発的に変化し、時間の経過とともに参照軌道との誤差が大きくなった場合に、過剰なトルクが発生する危険性があるからだ. 河合らは、レザバーコンピューティングによる状態依存の参照軌道生成を 2 リンク剛体ロボットアームに適用すると、学習に含まれない初期状態からでも、低トルクで目標状態に到達できることをシミュレーション上で示した [2]. また、インパルス状の外乱や観測ノイズが存在する場合でも、過剰なトルクを生成することなく目標状態に復帰できることを実証した.

空気圧人工筋は、その柔軟性と軽量性から、人間と安全に協働することが求められるロボットに適したアクチュエータとして、広く研究されている [3]. 空気圧アクチュエータの制御には、空気の圧縮性や供給速度などに起因する遅れが障壁となる [4]. 熱田らは、空気圧ベーンモータ駆動のロボットにおける遅れをレザバーコンピューティングにより推定したが、その大きさを一定と仮定している [論文出たら引用]. しかし、空気圧アクチュエータの応答遅れの大きさは圧縮空気供給系（チューブ・バルブなど）に依存 [5] し、通信や制御の環境によっても変化することを考慮すると、遅れはオンラインで推定しながら参照軌道を生成することが望ましい.

本研究では、空気圧人工筋駆動のロボットに、レザバーコンピューティングによる状態依存の参照軌道生成を適用し、最小限の力で外乱に適応する手法を提案する. 提案手法は、システムの遅れの推定値をオンラインで更新することで、ロボットの目標姿勢への追従精度を向上させることができると期待される. 実験では、図 1 に示すような、空気圧人工筋駆動のアームロボットが人間と協働して物品を運搬するタスクを実行する. 参照軌道が時間の関数として生成される場合は、ロボットが人間に先行して動作してしま

う可能性があるが、ロボットの状態に基づいて参照軌道を生成することで、人間がロボットを先導することができ、物品を安全に運搬できると期待される.

2 状態依存型参照軌道生成器における遅れのオンライン推定

2.1 ESN1 による Learning from Demonstration

物品運搬時に求められる動作を、人間がアームロボットを直接教示し、その動作をエコーステートネットワーク (ESN) で学習すること (Learning from Demonstration[8]) を考える. ESN がもつレザバー層では、入力データが再帰的に循環し、過去の入力の情報を含んだノード状態が出力層に送られるため、ESN は時系列データの学習に向いている [9]. 本節における ESN を ESN1 と呼び、その訓練および制御のスキームを図 2 に示す. 動作の教示時には、図 3 に示す 3 対 6 筋の空気圧人工筋駆動の 3 自由度アームロボットの、各関節変位がロータリーエンコーダで計測され、その時系列データが記録される. 学習時の ESN1 は、ノイズに対してロバストな Leaky Integrator 型のノード [10] のダイナミクスに従って更新される:

$$\mathbf{u}_1(k) = \mathbf{d}(k) \quad (2.1)$$

$$\tilde{\mathbf{r}}_1(k+1) = \phi_1(\mathbf{W}_1 \mathbf{r}_1(k) + \mathbf{W}_1^{\text{in}} \mathbf{u}_1(k)) \quad (2.2)$$

$$\mathbf{r}_1(k+1) = (1 - \alpha_1) \mathbf{r}_1(k) + \alpha_1 \tilde{\mathbf{r}}_1(k+1) \quad (2.3)$$

$$\mathbf{y}_1(k+1) = \mathbf{W}_1^{\text{out}} \mathbf{r}_1(k+1) \quad (2.4)$$

ここで、 $\mathbf{u}_1(k) \in \mathbb{R}^3$ は入力ベクトル、 $\mathbf{r}_1(k) \in \mathbb{R}^{N_1^T}$ はレザバー層の状態ベクトル、 ϕ_1 は非線形活性化関数、 α_1 はリーク率である. レザバー層の重み行列 $\mathbf{W}_1 \in \mathbb{R}^{N_1^T \times N_1^T}$ は確率 p_1 で結合し、区間 $[-1, 1]$ の一様分布からサンプリングされた後、スペクトル半径 ρ_1 でスケールされる. 入力重み行列 $\mathbf{W}_1^{\text{in}} \in \mathbb{R}^{N_1^T \times 3}$ は区間 $[-a_1, a_1]$ ($a_1 > 0$) の一様分布からサンプリングされる. 2 つの結合重み行列はランダムに初期化され、学習時は固定される. 動作の教示時に得られた関節変位の時系列データ $\mathbf{d}(k)$ を ESN1 に入力することで、次の時刻の関節変位 $\mathbf{d}(k+1)$ を推定し、教示された動きを再現する. したがって、出力重み行列




Fig.1 空気圧人工筋駆動のアームロボットと人間の協働運搬タスク [6]




Fig.2 ESN1 による Learning from Demonstration[7]

$\mathbf{W}_1^{\text{out}} \in \mathbb{R}^{N_1^v \times N_1^t}$ は、教示時の関節変位と ESN1 の出力の差を最小化するように、リッジ学習により最適化される:

$$\mathbf{W}_1^{\text{out}} = \arg \min_{\mathbf{W}_1^{\text{out}}} \frac{1}{N_1^v} \sum_{i=1}^{N_1^v} \left(\sum_{k=0}^{M-1} (d_i(k+1) - y_{1,i}(k))^2 + \beta \|\mathbf{w}_{1,i}^{\text{out}}\|^2 \right) \quad (2.5)$$

ここで、 M は教示データの最大時刻、 $\mathbf{w}_{1,i}^{\text{out}}$ は $\mathbf{W}_1^{\text{out}}$ の i 行目である。また $\beta_1 > 0$ は正則化パラメータであり、入力データに対する過学習を防ぐ。

学習後の ESN1 にはロボットの現在の関節変位が入力され、(2.2) 式、(2.3) 式および (2.4) 式によって更新される:

$$\mathbf{u}_1(k) = \mathbf{q}(k) \quad (2.6)$$

タスク実行時には、(2.6) 式によってロボットの関節変位 $\mathbf{q}(k)$ が ESN1 にフィードバックされるため、現在の状態に応じて適応的に参照軌道を生成することができる。人間がロボットを直接動かして動作を教示したときとは異なり、ロボットを駆動して動作を再現するときには、遅れ τ が存在するため、ESN1 の出力を $(\tau + 1)$ ステップ後の目標関節変位とする:

$$\mathbf{y}_1(k) = {}^d\mathbf{q}(k + \tau + 1) \quad (2.7)$$

ただし、全ての関節で τ は等しいと仮定する。時刻 $(k + \tau + 1)$ において目標関節変位に追従させるために、バルブ電圧 $\mathbf{v}(k) \in \mathbb{R}^6$ を次式で計算する:

$$\mathbf{v}(k) = \mathbf{K}_P ({}^d\mathbf{q}(k + \tau + 1) - \mathbf{q}(k)) - \mathbf{K}_D \dot{\mathbf{q}}(k) \quad (2.8)$$

ただし、 $\mathbf{K}_P \in \mathbb{R}^{6 \times 3}$ および $\mathbf{K}_D \in \mathbb{R}^{6 \times 3}$ はそれぞれ比例ゲイン、微分ゲインである。

2.2 ESN2 による遅れを組み込んだダイナミクスの学習

熱田らは、空気圧バーモータ駆動のロボット Affetto にモータバブリング [11, 12] をさせ、ある姿勢・速度を実現するために入力すべきバルブ電圧を学習する際に、遅れを陽に組み込んだ [論文出たら引用]。本節における ESN を ESN2 と呼ぶ。図 3 の腱駆動アームロボットにおいて、モータバブリングからそのダイナミクスを ESN2 で学習する際には、ロータリエンコーダの値 q や拮抗筋の圧力センサ値 p^+ , p^- に加え、腱の緩みを考慮するために張力センサの値 T^+ , T^- を使用する。すなわち、各関節に対して、

$$\mathbf{s}(k) = [q(k), \dot{q}(k), T^+(k), T^-(k), p^+(k), p^-(k)] \quad (2.9)$$

を測定する。ただし、 k ($0 \leq k \leq K$) はモータバブリングにおけるステップを表す。この $\mathbf{s}(k)$ に対し、

$$\mathbf{x}(j) = \mathbf{s}(j + \tau_{\max} + 1) \quad (2.10)$$

を ESN2 への入力ベクトルとする。ただし、 j ($0 \leq j \leq K - \tau_{\max} - 1$) は ESN2 における更新ステップを表す。遅れの大きさを τ ステップ ($\tau_{\min} \leq \tau \leq \tau_{\max}$) と仮定し、図 4 に示すように $\mathbf{x}(j)$ を時系列に並べることで、行列 $\mathbf{X} \in \mathbb{R}^{(K - \tau_{\max}) \times 6}$ を構成する:

$$\mathbf{X} = [\mathbf{x}(0), \mathbf{x}(1), \dots, \mathbf{x}(K - \tau_{\max} - 1)]^T \quad (2.11)$$




Fig.3 肩 2 自由度、肘 1 自由度のアームロボット




Fig.4 ESN2 における先読み参照埋め込み

また, 拮抗筋のバルブ電圧

$$\mathbf{v}(k) = [v^+(k), v^-(k)] \quad (2.12)$$

に対して,

$$\mathbf{y}(j) = [\mathbf{v}(j), \mathbf{v}(j+1), \dots, \mathbf{v}(j + \tau_{max} - \tau_{min})] \quad (2.13)$$

を構成し, これを時系列で並べることで, 行列 $\mathbf{Y} \in \mathbb{R}^{(K-\tau_{max}) \times 2(\tau_{max}-\tau_{min}+1)}$ を構成する:

$$\mathbf{Y} = [\mathbf{y}(0), \mathbf{y}(1), \dots, \mathbf{y}(K - \tau_{max} - 1)]^T \quad (2.14)$$

このようにして得られた教師データ (\mathbf{X}, \mathbf{Y}) に対して, 回帰モデル $f: \mathbf{X} \mapsto \mathbf{Y}$ を ESN2 により学習する:

$$\mathbf{u}_2(j) = \mathbf{x}(j) \quad (2.15)$$

$$\tilde{\mathbf{r}}_2(j+1) = \phi_2(\mathbf{W}_2 \mathbf{r}_2(j) + \mathbf{W}_2^{\text{in}} \mathbf{u}_2(j)) \quad (2.16)$$

$$\mathbf{r}_2(j+1) = (1 - \alpha_2) \mathbf{r}_2(j) + \alpha_2 \tilde{\mathbf{r}}_2(j+1) \quad (2.17)$$

$$\mathbf{y}_2(j+1) = \mathbf{W}_2^{\text{out}} \mathbf{r}_2(j+1) \quad (2.18)$$

これにより, システムに τ ステップの遅れが存在するとき, 時刻 $(k + \tau + 1)$ において各関節の角度を目標値に追従させるために, 時刻 k において入力すべきバルブ電圧を推定することができる.

学習後, 全ての τ に対する ESN2 の出力を比較し, 最も

1 に近い決定係数 R^2 を与える τ を同定する:

$$R^2(\tau) = 1 - \frac{\sum_{k=\tau_{max}-\tau}^{K-\tau-1} \|\mathbf{v}(k) - \hat{\mathbf{v}}(k)\|^2}{\sum_{k=\tau_{max}-\tau}^{K-\tau-1} \|\mathbf{v}(k) - \bar{\mathbf{v}}\|^2} \quad (2.19)$$

$$\bar{\mathbf{v}} = \frac{1}{K - \tau_{max}} \sum_{k=\tau_{max}-\tau}^{K-\tau-1} \mathbf{v}(k) \quad (2.20)$$

$$\tau_{\text{initial}} = \arg \max_{\tau_{\min} \leq \tau \leq \tau_{\max}} R^2(\tau) \quad (2.21)$$

ただし, $\mathbf{v}(k)$ は時刻 k に実際に入力されたバルブ電圧, $\hat{\mathbf{v}}(k)$ は時刻 k におけるバルブ電圧の推定値である. 以上により, モータバブリング時の遅れは τ_{initial} ステップであると推定される.

2.3 遅れのオンライン推定

ロボットの制御中に, 通信状況や圧縮空気供給系のダイナミクスが変化し, 遅れが変化する可能性がある. ロボットが ESN1 により教示された動作を再生している際に, 時刻 k における遅れの推定値 $\tau(k)$ を ESN2 によりオンラインで更新することを考える. $\tau(0) = \tau_{\text{initial}}$ とし, 次のように $R^2(\tau(k))$ を計算する:

$$R^2(\tau(k)) = 1 - \frac{\sum_{i=\tau+1}^{\tau+n} \|\mathbf{v}(k-i) - \hat{\mathbf{v}}(k-i)\|^2}{\sum_{i=\tau+1}^{\tau+n} \|\mathbf{v}(k-i) - \bar{\mathbf{v}}\|^2} \quad (2.22)$$

$$\bar{\mathbf{v}} = \frac{1}{n} \sum_{k=\tau+1}^{\tau+n} \mathbf{v}(k-i) \quad (2.23)$$

$$(2.24)$$

同様に、 $R^2(\tau(k) - 1)$, $R^2(\tau(k) + 1)$ を計算し、次のように $\tau(k + 1)$ を更新する:

$$\tau(k+1) = \begin{cases} \tau(k) - 1 & \text{if } R^2(\tau(k) - 1) > R^2(\tau(k)) + \delta, \\ \tau(k) + 1 & \text{if } R^2(\tau(k) + 1) > R^2(\tau(k)) + \delta, \\ \tau(k) & \text{otherwise.} \end{cases} \quad (2.25)$$

$\delta > 0$ はセンサノイズやモデル誤差による τ の振動を防ぐ。(2.25) 式により更新された τ は (2.7) 式に代入され、ロボットの目標関節変位への追従精度を向上させるのに寄与すると期待される。

3 遅れ推定アルゴリズムの課題

- $\tau_{min}, \tau_{max}, n, \delta$ の設定が難しい
- 遅れの大きさは制御周期の整数倍と仮定している
- 全ての関節で遅れが等しいと仮定している
- 局所解に陥る可能性がある（真の遅れが 20 ステップだったとしても、現在の遅れの推定値が 10 ステップで、 $R^2(10) \geq R^2(9), R^2(11)$ なら、遅れは更新されない）
- 遅れ推定の精度はモータバブリングで得られたデータに依存する

4 将来の展望

- 5 筋 10 関節ハンドと組み合わせ（ガワはオープンソース [13, 14]。ハンドにつけたシリコンセンサの入力が既定の閾値以上になった場合、各指に圧縮空気を供給すると、運搬する物品に対して劣駆動で指が巻き付く。
- 双腕協調（状態依存の参照軌道生成なので、片腕の状態をもう一方の腕にフィードバックすれば、片腕だけモニタリングすればいい）
- 運搬タスク以外への拡張

参考文献

- [1] Auke Ijspeert, Jun Nakanishi, and Stefan Schaal. Learning attractor landscapes for learning motor primitives. *Advances in Neural Information Processing Systems*, 15, 2002.
- [2] 河合 祐司, 熱田 洋史, 浅田 稔. レザバーコンピューティングを用いた適応的な参照軌道生成による外乱にロバストな制御. 第 41 回日本ロボット学会学術講演会予稿集, 2023.
- [3] Frank Daerden and Dirk Lefeber. Pneumatic artificial muscles: Actuators for robotics and automation. *European journal of mechanical and environmental engineering*, 47:11–21, 2002.
- [4] Dang Xuan Ba and Kyoung Kwan Ahn. A robust time-delay nonlinear controller for a pneumatic artificial muscle. *International Journal of Precision Engineering and Manufacturing*, 19(1):23–30, 2018.
- [5] Toshihiro Tagami, Tetsuro Miyazaki, Toshihiro Kawase, Takahiro Kanno, and Kenji Kawashima. Pressure Control of a Pneumatic Artificial Muscle Including Pneumatic Circuit Model. *IEEE Access*, 8:60526–60538, 2020.
- [6] 岡崎 安直, 山本 正樹, 小松 真弓, 津坂 優子, 足達 勇治. 空気圧人工筋による人に対して安全な多自由度ロボットアーム技術の開発. 日本ロボット学会誌, 28(3):302–310, 2010.
- [7] 熱田 洋史, 河合 祐司, 浅田 稔. エコーステートネットワークを用いた冗長ロボットアームの適応的な運動生成. 電子情報通信学会技術研究報告, 123(233):17–22 2023.
- [8] Stefan Schaal. Learning from demonstration. *Advances in neural information processing systems*, 9:1040–1046, 1996.
- [9] Herbert Jaeger. The” echo state” approach to analysing and training recurrent neural networks-with an erratum note. *German National Research Center for Information Technology GMD Technical Report*, 148(34):13, 2001.
- [10] Herbert Jaeger, Mantas Lukoševičius, Dan Popovici, and Udo Siewert. Optimization and applications of echo state networks with leaky-integrator neurons. *Neural Networks*, 20(3):335–352, 2007.
- [11] Ryo Saegusa, Giorgio Metta, Giulio Sandini, and Sophie Sakka. Active motor babbling for sensory-motor learning. pages 794 – 799, 2009.
- [12] Y. Demiris and Anthony M. Dearden. From motor babbling to hierarchical learning by imitation: a robot developmental pathway. 2005.
- [13] Anya Zorin, Irmak Guzey, Billy Yan, Aadithya Iyer, Lisa Kondrich, Nikhil X. Bhattasali, and Lerrel Pinto. Ruka: Rethinking the design of humanoid hands with learning. *Robotics: Science and Systems (RSS)*, 2025.
- [14] Clemens C. Christoph, Maximilian Eberlein, Filipp Katsimalis, Arturo Roberti, Aristotelis Sym-

petheros, Michel R. Vogt, Davide Liconti, Chenyu Yang, Barnabas Gavin Cangan, Ronan J. Hinchet, and Robert K. Katzschmann. Orca: An open-source, reliable, cost-effective, anthropomorphic robotic hand for uninterrupted dexterous task learning, 2025.