

エコーステートネットワークを用いた冗長ロボットアームの 適応的な運動生成

熱田 洋史[†] 河合 祐司[†] 浅田 稔^{††,†,†††,††††}

[†] 大阪大学先導的学際研究機構附属共生知能システム研究センター 〒565-0871 大阪府吹田市山田丘 1-1

^{††} 大阪国際工科専門職大学 〒530-0001 大阪府大阪市北区梅田 3-3-1

^{†††} 中部大学創発学術院 〒487-8501 愛知県春日井市松本町 1200

^{††††} 情報通信研究機構脳情報通信融合研究センター 〒565-0871 大阪府吹田市山田丘 1-4

E-mail: [†]{hiroshi.atsuta,kawai,asada}@otri.osaka-u.ac.jp

あらまし ロボットの動作教示において直接教示法は手軽である一方、初期姿勢のずれや外乱によって過度な加速度が発生する問題がある。本研究では、教示した運動の関節変位系列をエコーステートネットワーク (ESN) に学習させ、その出力を参照軌道として用いることで、複数ターゲットへのリーチングや曲線の追従を実現する。またロボットの冗長性のため、目標ターゲット変更や外乱によりロボットは未学習の状態に容易に遷移するが、訓練後の ESN は未学習状態を汎化し学習した軌道に収束する運動を生成する。それにより未学習状態においてもロボットが過度な加速度を発生させずに適応的に振る舞うことを数値シミュレーションによって確認する。

キーワード レザバーコンピューティング, エコーステートネットワーク, リカレントニューラルネットワーク, 冗長自由度, ロボットアーム, 模倣学習

Adaptive motion generation for a redundant robot arm using an echo state network

Hiroshi ATSUTA[†], Yuji KAWAI[†], and Minoru ASADA^{††,†,†††,††††}

[†] Symbiotic Intelligent Systems Research Center, Open and Transdisciplinary Research Initiatives, Osaka University
1-1 Yamadaoka, Suita, Osaka, 565-0871 Japan

^{††} International Professional University of Technology in Osaka 3-3-1 Umeda, Kita-ku, Osaka, 530-0001 Japan

^{†††} Chubu University Academy of Emerging Sciences 1200 Matsumoto-cho, Kasugai, Aichi, 487-8501 Japan

^{††††} Center for Information and Neural Networks, National Institute of Information and Communications Technology
1-4 Yamadaoka, Suita, Osaka, 565-0871 Japan

E-mail: [†]{hiroshi.atsuta,kawai,asada}@otri.osaka-u.ac.jp

Abstract Teaching playback is a convenient method to instruct robots how to move. However, this method has an issue of excessive acceleration caused by initial posture deviations or external disturbances. In this study, we propose a motion generation system for a redundant robotic arm, in which an echo state network (ESN) learns the joint angle time series of demonstrated motions, and then, it generates reference trajectories to achieve the learned motions (e.g., reaching multiple targets and tracking a curve). Even though changes of the target position and external disturbances can easily transition the robot to unlearned states due to its redundancy, the trained ESN can generalize such unlearned states to generate motions that converge toward the demonstrated trajectories. It is confirmed through computer simulations that it allows the robot to behave adaptively while avoiding excessive acceleration, even in the unlearned states.

Key words reservoir computing, echo state network, recurrent neural network, redundant robotic arm, learning from demonstration

1 はじめに

産業用ロボットアームの制御方法は現在でも教示再生 (teaching/playback) 方式が主流である [1]. ロボットの先端を作業手順に従って動かしながら時々刻々の関節変位を記録する方法は直接教示法と呼ばれる. 動作生成時の制御には, 得られた点間の連続経路をスプライン補間等により時刻の関数として表現した参照軌道に従い, 各関節に独立な位置と速度の線形フィードバックを構成する. ロボットは非線形かつ多自由度で関節間に動的干渉があるが, これでも十分に機能する [2].

直接教示法による教示再生方式は作業者に専門的なプログラミング技術を必要としない点で手軽に扱えるが, 人間と隔離した環境下でロボットが同じ動作を繰り返す場合にのみ有効である. 人間と共存・協働する環境下では, 人間や障害物との接触による外力に対する柔軟性, 作業指令の変更に対する即応性, 新しい作業を教示する上での簡便性が求められる. 単純な教示再生ではなく, 作業者が教示した動作から実際のタスク実行時に必要な運動を機械学習等によって生成する技術は広く Learning from Demonstration [3] と呼ばれ, 数多くの手法が提案されている [4]. 中でも外乱に対する柔軟性や作業指令の変更に対する即応性を重視する場合, 時刻の関数で表現された参照軌道を生成するのではなく, 時刻を陽に含まない状態フィードバックのみで動作生成を行う方が有効である. Ijspeert *et al.* [5] は多数の運動軌道から事前に仮定した非線形力学系のパラメータを最適化することで, 時刻や初期姿勢に依存せず外乱にロバストな運動生成を実現した. Khansari-Zadeh and Billard [6] は力学系の構造を事前に仮定するのではなく, 軌道の終端において漸近収束するという拘束条件に基づいて最適化したガウス混合モデルにより運動軌道データから力学系を学習する方法を提案した. 初期姿勢の変動や外乱によって手先位置が変化しても, 常に現在の状態から時間発展する軌道に沿って運動を生成するため, 過度に大きな加速度を発生しにくい. しかし, 安定な力学系を学習するための拘束条件を到達運動や周期運動などのタスクの目的に応じて事前に設定する必要がある. また彼ら [6] は, 作業空間上の参照位置から冗長自由度のある関節空間上の参照値を計算する上で生じる不良設定性 [7] について言及していない. 作業空間上で学習した安定な力学系の微分同相写像によって得られるリーマン多様体の幾何学的構造から関節レベルのインピーダンス制御における適切なスティフネスパラメータを推定することで冗長自由度ロボットを制御する手法 [8] も提案されているが, いずれもガウス混合モデルの学習に伴う計算コストが高い.

一方, 比較的小さな計算量で時系列パターンを効率よく学習できるレザパーコンピューティング [9], [10] において, カオス力学系を時間発展して得られる時系列を訓練することで, もとの力学系のアトラクタや分岐といった特徴を再現することが報告されている [11]~[13]. 結合重みが固定されたリカレントニューラルネットワークをレザパーとするエコーステートネットワーク (ESN) に対して, 元の力学系が安定であればその力学系に位相共役な多様体を出力するリードアウト重みが存

在することが 1 次元の時系列に限って数学的に証明されている [12]. 多次元の時系列においては, Kim *et al.* [13] が Lorenz アトラクタの解軌道をサンプリングした時系列の現在の信号を入力, 1 ステップ先の信号を教師信号とするように訓練した後, ネットワークの出力を次時刻の入力とするフィードバックループを形成することで自律的に駆動させると, もとの Lorenz アトラクタの幾何学構造や分岐構造を再現することを実験的に示した. このことから ESN には時系列の背後にある力学系の幾何学的特徴を再現する能力があると考えられ, この性質を応用して任意のタスクを実現する力学系を少数の動作教示から学習できる可能性がある.

そこで本研究では, ESN に教示した運動の関節変位系列を学習させ, その出力を参照軌道として関節レベルで線形フィードバック制御を施すシステムを提案する. ロボットの冗長性のため, 初期値変動や外乱, 目標ターゲット変更によりロボットは未学習の状態に容易に遷移するが, 訓練後の ESN は未学習状態を汎化し学習した軌道に収束する参照軌道を生成する. またロボットの現在の状態に基づいた参照軌道を常に出力するため, 過度な加速度の発生を避けることができる. このことを確認するため, 単一ターゲットへの到達運動, 複数ターゲットに対して任意のタイミングで目標ターゲットを切り替える到達運動, 滑らかな曲線を描く周期運動といったタスクを学習させ, 初期値変動や外乱に対して柔軟に振る舞うか数値シミュレーションを通じて検証する.

2 予備調査：時系列軌道からのアトラクタ推定

2.1 エコーステートネットワーク (ESN)

ESN は結合重みを固定したレザパー層に学習可能なリードアウト層を接続したリカレントニューラルネットワークの一種である [10]. N_u 次元の入力ベクトル時系列 $\mathbf{u}(k) \in \mathbb{R}^{N_u}$ が与えられるとき, その元となった力学系のアトラクタ構造を ESN によって推定することを考える.

N_r 個の素子で構成されるレザパー層の離散時刻 $k \in \{0, 1, \dots, K\}$ における状態 $\mathbf{r}(k) \in \mathbb{R}^{N_r}$ の離散化ダイナミクスは, 次式のように再帰的に定義される.

$$\tilde{\mathbf{r}}(k+1) = \varphi(\mathbf{W}\mathbf{r}(k) + \mathbf{W}^{\text{in}}\mathbf{u}(k)) \quad (1)$$

$$\mathbf{r}(k+1) = (1 - \alpha)\mathbf{r}(k) + \alpha\tilde{\mathbf{r}}(k+1) \quad (2)$$

ただし $\mathbf{W} \in \mathbb{R}^{N_r \times N_r}$ は結合確率 p のリカレント結合重み行列で, 区間 $[-1, 1]$ の一様分布からサンプリングされたのちスペクトル半径が ρ となるようにスケーリングされる. $\mathbf{W}^{\text{in}} \in \mathbb{R}^{N_r \times N_u}$ は入力重み行列で, 区間 $[-a, a]$ の一様分布からサンプリングされる. ただし $a > 0$ は入力スケーリングである. また, $\varphi: \mathbb{R}^{N_r} \rightarrow \mathbb{R}^{N_r}$ は活性化関数, α は漏れ率である.


リードアウト層は次式で定義される.

$$\mathbf{v}(k) = \mathbf{W}^{\text{out}}\mathbf{r}(k) \quad (3)$$


ただし $\mathbf{v}(k) \in \mathbb{R}^{N_v}$ はモデルの出力, $\mathbf{W}^{\text{out}} \in \mathbb{R}^{N_v \times N_r}$ は出力重み行列である.

表 1: ESN の訓練に用いたパラメータ

パラメータ	説明	2.2 節の値	4 節の値
N_r	レザバーの素子数	300	400
a	入力スケーリング	0.1	0.001
p	結合確率	0.1	0.1
ρ	スペクトル半径	0.95	0.95
α	漏れ率	0.99	0.4
φ	活性化関数	tanh	tanh



(a): 式 (7) の相図 (b): 訓練に用いた軌道 (c): 推定された軌道群



(d): 式 (8) の相図 (e): 訓練に用いた軌道 (f): 推定された軌道群

図 1: ESN による安定なアトラクタをもつ力学系の推定

レザバー状態 $\mathbf{r}(0) = [0, \dots, 0]^T$ と初期化し, 入力系列 $\mathbf{u}(k)$ に対して式 (1),(2) によってレザバー状態を再帰的に計算した後, 次式の最適化問題を解くことで \mathbf{W}^{out} を得る.

$$\mathbf{W}^{\text{out}} = \arg \min_{\mathbf{W}^{\text{out}}} \frac{1}{N_v} \sum_{i=1}^{N_v} \left(\sum_{k=0}^K \left(d_i(k) - v_i(k) \right)^2 + \beta \|\mathbf{w}_i^{\text{out}}\|^2 \right) \quad (4)$$

ただし $\mathbf{w}_i^{\text{out}}$ は \mathbf{W}^{out} の第 i 行, $\beta > 0$ は正則化パラメータ, $\|\cdot\|$ はユークリッドノルムを表す. また $\mathbf{d}(k) \in \mathbb{R}^{N_v}$ は ESN に推定させる時系列であり, この場合は入力時系列 $\mathbf{u}(k)$ に一致する.

出力重み行列 \mathbf{W}^{out} を訓練した後, 次式で定義される自律力学系のもとで時間発展させることで, 推定された時系列 $\mathbf{x}(k)$ が得られる.

$$\mathbf{s}(k+1) = (1-\alpha)\mathbf{s}(k) + \alpha\varphi(\mathbf{W}\mathbf{s}(k) + \mathbf{W}^{\text{in}}\mathbf{x}(k)) \quad (5)$$

$$\mathbf{x}(k+1) = \mathbf{W}^{\text{out}}\mathbf{s}(k+1) \quad (6)$$

ただし $\mathbf{s}(k) \in \mathbb{R}^{N_r}$ は自律駆動時のレザバー状態であり, $\mathbf{s}(0) = \mathbf{r}(0)$ および適当な駆動入力 $\mathbf{x}(0) = \mathbf{u}'(0)$ によって初期化してから駆動される.

2.2 ESN による安定なアトラクタの推定

2.1 節で述べた方法によって Macky-Glass アトラクタや Lorenz アトラクタといったカオスアトラクタの幾何学的特徴が再現できることが報告されている [11], [13] が, ロボットの運動生成に応用する上で差し当たりカオス的な運動は必要ない. そこで基礎的な運動として到達運動や周期運動を想定し, 平衡点およびリミットサイクルをアトラクタとする力学系に対して時系列からアトラクタを推定可能か検証する.

次式で表される 2 階の線形微分方程式を考える.

表 2: 推定された軌道の RMSE の平均値および分散

	avg. of RMSE	var. of RMSE
線型微分方程式 (式 (7))	1.99×10^{-3}	4.15×10^{-6}
van der Pol 方程式 (式 (8))	1.15×10^{-1}	1.04×10^{-2}

$$a\ddot{x} + b\dot{x} + cx = 0 \quad (7)$$

式 (7) は係数を適切に選ぶと相平面上に安定な平衡点をもつ. $a = 1, b = 3, c = 4$ とした場合の相図を図 1(a) に示す. 次にこの相平面上的ランダムな 10 点を初期値として式 (7) に従って時間発展して得られる解軌道を図 1(b) に示す. この時系列を表 1 に示す ESN で訓練し, 訓練に用いた初期値とは異なるランダムな点を 100 点選び式 (5),(6) に従って自律駆動させた結果を図 1(c) に示す.

また安定なリミットサイクルをもつ力学系として, 次式で表される van der Pol 方程式を考える.

$$\ddot{x} = \mu(1-x^2)\dot{x} - x \quad (8)$$

$\mu = 1$ としたときの相図を図 1(d) に示す. 線形力学系の場合と同様, 図 1(e) に示すランダムな 10 点を初期値とする解軌道を表 1 の ESN で訓練し, 新たにランダムな初期値 100 点から時間発展させたときの軌道群を図 1(f) に示す.

推定した力学系において, i 番目の初期値 $\mathbf{x}(0)$ から訓練後の ESN によって時間発展させた軌道 $[\mathbf{x}(k) \ \dot{\mathbf{x}}(k)]^T$ と元の力学系において時間発展させた解軌道 $[\mathbf{x}^{\text{sc}}(k) \ \dot{\mathbf{x}}^{\text{sc}}(k)]^T$ に対して次式で表される二乗平均平方根誤差 (RMSE) を計算する.

$$E(\mathbf{x}, \mathbf{x}^{\text{sc}}) = \frac{1}{2} \sum_{j=1}^2 \left(\sqrt{\frac{1}{K+1} \sum_{k=0}^K (i_{x_j}(k) - i_{x_j}^{\text{sc}}(k))^2} \right) \quad (9)$$

ただし $i_{x_0} = \mathbf{x}$, $i_{x_1} = \dot{\mathbf{x}}$ で上付き文字 sc も同様である.

両方の力学系に対して, 式 (9) を計算した結果の平均値および分散を表 2 に示す. 図 1(c), 図 1(f) および表 2 から訓練後の ESN が元の力学系の構造およびアトラクタを再現していることが確認できる.

3 ESN による適応的な参照軌道生成システム


ロボットを直接教示して得られる関節変位時系列を訓練データとして ESN を訓練することで, 教示した動作を再現する運動を生成することが期待される.

直接教示法によって得られた関節変位時系列に対して図 2(a) に示すように ESN を訓練する. ただし, 教示したタスクを互いに区別するためのベクトル (例えば目標ターゲット位置や動作の種類をラベリングした ID) $\mathbf{c} \in \mathbb{R}^{N_c}$ および離散時刻 $t \in \{0, 1, \dots, T\}$ における目標関節変位 $\mathbf{d}(t)$ を ESN の入力層に与えるベクトル $\mathbf{u}(t)$ とする. すなわち,


$$\mathbf{u}(t) = [\mathbf{c}(t); \mathbf{d}(t)] \quad (10)$$

とする. ただし $[\cdot; \cdot]$ は列ベクトルの連結を表す.

訓練後の ESN を用いて n 自由度ロボットの運動生成を行う際は, 図 2(b) に示すように, 時刻 t において実行するタスク入



(a): 教示した動作に基づく ESN の訓練スキーム



(b): 運動生成時におけるロボットの制御スキーム

図 2: ESN による適応的な参照軌道生成システムの構成




図 3: ロボットモデル





図 4: 教示に用いた軌道



(a): 訓練した ESN による制御 (b): スプライン補間による制御

図 5: ランダムな初期姿勢から到達運動を実行した結果

表 3: 4 自由度ロボットのパラメータ

	リンク 1	リンク 2	リンク 3	リンク 4
リンク長 l [m]	0.1	0.25	0.25	0.15
重心位置 l_g [m]	0.05	0.1	0.1	0.05
リンク質量 m [kg]	0.5	1.0	1.0	0.5
慣性モーメント I [kgm ²]	0.005	0.01	0.007	0.003

力ベクトル $c(t)$ およびロボットの現在の関節変位 $q(t)$ を ESN の入力層に与え、ネットワークの出力 $y(t+1)$ を次式で求める。

$$u(t) = [c(t); q(t)] \quad (11)$$

$$s(t+1) = (1 - \alpha)s(t) + \alpha\varphi(Ws(t) + W^{\text{in}}u(t)) \quad (12)$$

$$y(t+1) = W^{\text{out}}s(t+1) \quad (13)$$

このネットワーク出力 $y(t+1)$ を目標関節変位 $d_q(t)$ とするようロボットの制御する。したがってロボットの駆動トルク $\tau(t+1)$ は次式の線形フィードバックで計算する。

$$\tau(t+1) = K_P(d_q(t+1) - q(t)) - K_D\dot{q}(t) \quad (14)$$

ただし $K_P \in \mathbb{R}^{n \times n}$ および $K_D \in \mathbb{R}^{n \times n}$ はそれぞれ比例ゲイン、微分ゲインを表す。

式 (5),(6) で自律駆動する場合と異なり、ESN の入力層にはタスクを表す $c(t)$ およびロボットの関節変位 $q(t)$ を与えるため、目標ターゲットの変更や現在の状態に適応的な運動を生成することが期待される。

4 数値シミュレーション

4.1 ロボットモデル

ESN による適応的な運動生成システムの有効性を確認するため、図 3 に示す平面 4 自由度ロボットアームの順動力学シミュレーションを実装し数値シミュレーションを行った。ロボットの運動方程式は次式で表される (時刻 t の表記は省略)。

$$H(q)\ddot{q} = \tau + J_E^T(q)f_E - b(q, \dot{q}) \quad (15)$$

ただし $q \in \mathbb{R}^4$ は関節変位を表す関節ベクトル、 $\tau \in \mathbb{R}^4$ は関節




図 6: 初期姿勢が変動した場合の参照軌道と駆動トルクの比較 (上段: 点線が参照軌道, 実線が関節軌道を表す)

に働く駆動力ベクトル、 $H(q) \in \mathbb{R}^{4 \times 4}$ は慣性行列、 $b(q, \dot{q}) \in \mathbb{R}^4$ は遠心力およびコリオリ力、 $f_E \in \mathbb{R}^2$ は手先に働く接触力、 $J_E \in \mathbb{R}^{2 \times 4}$ は関節速度 \dot{q} から手先速度 v_E へのヤコビ行列である。ここでは外力は手先のみに働くとした。


以下で述べる数値シミュレーションでは表 3 に示すロボットパラメータを用いた。線形フィードバック制御器の比例・微分ゲインはそれぞれ $K_P = \text{diag}\{35.0, 35.0, 35.0, 35.0\}$, $K_D = \text{diag}\{0.4, 0.4, 0.4, 0.4\}$ とした。また数値積分は積分時間幅 $\Delta t = 10[\text{ms}]$ で 4 次の Runge-Kutta 法を用いた。

運動を教示する際は、コンピュータ画面上でロボットの手先をマウスでドラッグし、サンプリング時間毎に逆運動学を解いた結果の関節変位を記録することで目標関節変位の時系列を取得した。

4.2 単一目標への到達運動 (スプライン補間との比較)

まずロボットを適当な姿勢で初期化し、目標ターゲット $p_g = [0.0 \ 0.4]^T$ に到達するおよそ 10 秒程度のリーチング運動を一回のみ教示した。教示した軌道を図 4 に示す。得られた目標時系列に対して表 1 に示すパラメータを持つ ESN を 3 節で述べた方法で訓練した後、教示時の初期姿勢から少し変動したランダムな 10 点から運動を実行した結果を図 5(a) に示す。いずれのケースも目標ターゲットに到達した。

提案システムが生成する参照軌道を評価するため、従来の教示再生方式で使われるスプライン補間によって参照軌道を生



(a): 訓練した ESN による制御 (b): スプライン補間による制御

図 7: 運動中に外力を与えた場合の挙動

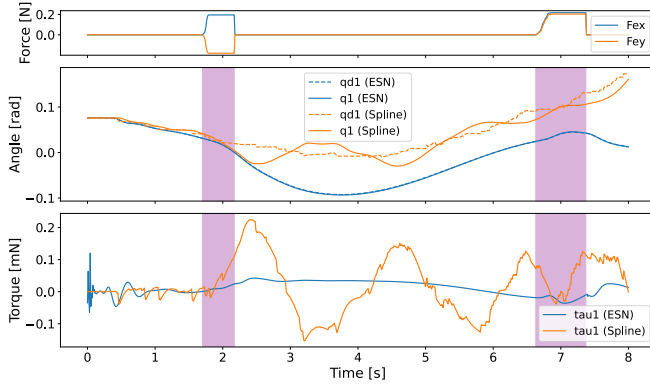



図 8: 運動中に外力を与えた時の参照軌道と駆動トルクの比較 (中段: 点線が参照軌道, 実線が関節軌道を表す)

成した場合と比較する。同じ初期姿勢から ESN とスプライン補間で制御したときの第 1 関節の参照軌道・関節変位および関節に発生した駆動トルクを図 6 の上下にそれぞれ示す。ただし ESN のレザバ出力が参照軌道に等しいことに注意されたい。スプライン補間による制御では、初期姿勢が参照軌道からずれているため、運動開始直後に大きな駆動トルクを発生し挙動が振動的になる。一方、ESN による制御では運動開始直後からロボットの状態(関節変位)に基づいて参照軌道を生成するため大きなトルクが発生しないことがわかる。

次に、運動中に適当なタイミングで手先に外力を与えたときの挙動を ESN とスプライン補間で比較する。同じ向き・大きさの外力 f_E を同じタイミングで与えたときの軌道を図 7 に示す。ただし紫色の矢印は外力の方向と大きさの目安を表す。スプライン補間による制御では、外力に対して抵抗し、外力除去時にその反動でオーバーシュートが発生している。一方、ESN による制御では、外力に対して馴染むように手先が移動し、外力除去時に緩やかにターゲットに向かっていく。また、与えた外力および各々の制御方法において第 1 関節の参照軌道と関節変位、発生した駆動トルクを図 8 にそれぞれ示す。スプライン補間による制御では、最初の外力が与えられることで参照軌道から大きく外れるため大きな駆動トルクが発生している。そのため外力除去後も振動的な挙動が解消できない。一方、ESN による制御では外力が与えられても実際の関節変位から参照軌道が生成されるため、過度に大きなトルクを発生させないことがわかる。


4.3 単一目標への到達運動(汎化性能の検証)

より多様な初期姿勢から特定の目標ターゲットに到達する



(a): 教示した運動軌道群 (b): 様々な姿勢から開始した結果

図 9: 複数回の運動を教示した結果



(a): 第 1 関節と第 2 関節 (b): 第 3 関節と第 4 関節

図 10: 図 9(b) の運動の関節空間における軌道




図 11: 最終姿勢における手先位置 図 12: 運動中により大きな外乱を与えた時の軌道


運動を学習できるか確認するために、図 9(a) に示す教示データに基づいて ESN を訓練した。訓練後、ランダムな 100 点の初期姿勢から運動させた結果、90 例が成功した。ただし手先とターゲット間の距離が 0.02[m] に 3 秒以上留まった場合に成功と判定した。成功例のみを図 9(b) に示す。

図 10 は図 9(b) の運動軌道を関節空間上にプロットした結果である。ただし×印が運動開始時の状態、○印が運動終了時の状態を表す。提案した枠組みでは、教示した運動の関節変位軌道を直接学習するため、運動生成時に冗長自由度ロボットにおける不良設定問題を解く必要がない。図 9(b) と図 10 を比較すると、作業空間上では目標位置に収束するが、関節空間上では特定の位置に収束しないことがわかる。また、各々の運動の最終姿勢の平均と標準偏差を図 11 に示す。特定の姿勢に収束するのではなく、冗長性をもつゆえに様々な姿勢で収束することが確認できる。このことは、学習には関節変位系列のみを使っているにもかかわらず、手先が特定の位置に収束するように ESN が汎化されていることを示している。

また運動中に大きな外力を与えた時の軌道を図 12 に示す。4.2 節よりも大きな外力を与えたが手先位置を大きく変動させながら、最終的に目標ターゲットに収束できている。

4.4 複数目標への到達運動

タスクを表す入力ベクトル $c(t)$ を運動中に任意のタイミング



(a): 教示した運動軌道群 (b): 実際の運動軌道

図 13: 目標ターゲットを運動中に切り替えるタスク





図 14: 図 13(b) に対応する手先位置



(a): 異なる初期姿勢からの運動 (b): 外力を与えた結果

図 15: 円軌道の描画

で変更することで、目標ターゲットを切り替えることができるか確認する。ここでは2つの目標ターゲット $p_{g1} = [-0.2 \ 0.4]^T$, $p_{g2} = [0.2 \ 0.4]^T$ を用意し、それぞれの目標を表すIDをOne-hotベクトルとして表現した。それぞれの目標に対して10秒程度の運動を10回ずつ教示した運動軌道群を図13(a)に示す。

適当な初期姿勢から運動を生成し、任意のタイミングでタスク入力ベクトルを変化させたときの挙動を図13(b)、その際の目標ターゲット位置と手先位置の変化、および第1関節の参照軌道と関節変位を図14の上下にそれぞれ示す。目標ターゲットを変化させると、即座に参照軌道が変化し目標ターゲットに向かい始めることがわかる。

4.5 曲線を描く周期運動

最後に到達運動だけでなく、周期運動も同じ枠組みで学習できるか確認する。ここでは10秒程度の周期で円を3周する運動を教示した。訓練後のESNを用いて教示時とは異なる初期姿勢から運動を生成した場合の軌道を図15(a)に示す。初期姿勢にずれがある場合は、即座に教示した経路に収束せず、周期的な運動をしながら徐々に教示した円軌道に収束した。また運動中に外力を与えた結果を図15(b)に示す。外力を与えると一時的に円軌道から外れるものの、周期運動をするうちに徐々に教示した円軌道に収束することが確認できた。

5 おわりに

本研究では、時系列データからその背後に存在する力学系の

アトラクタ構造を推定できるESNの特性を応用し、ロボットに数回直接教示するだけで多様なタスクに対してロバストかつ柔軟に振る舞うシステムを提案した。平面リンクロボットモデルに基づく動力学シミュレータおよび運動教示・学習システムを実装し、単一ターゲットおよび複数ターゲットへの到達運動や円を描く周期運動を数回の動作教示で学習できることを確認した。また運動中に無造作に与えた外力や任意のタイミングで目標タスクを変更しても柔軟に振る舞うことが確認できた。学習には関節変位時系列を直接用いたため、運動生成時に逆運動学を解く必要がなく、探索空間が大きくなる冗長ロボットアームにおいても適用可能であることを示した。またタスクの事前知識に基づいて特定の制約条件を付加することなく、教示データを与えるだけでモデルフリーに運動生成が可能であることを確認した。今後、より多様なタスクにおいて提案システムが適用可能か検証し、実ロボットで実験を行う。

謝辞 本研究は、JST, CREST (JPMJCR17A4) の支援を受けたものであり、国立研究開発法人新エネルギー・産業技術総合開発機構 (NEDO) の委託業務 (JPNP16007) の結果得られたものである。

文 献

- [1] 原田研介, 万 偉偉, “産業用ロボットの次世代技術について,” 日本ロボット学会誌, vol.37, no.10, pp.915–918, 2019.
- [2] 有本 卓, “サーボ理論とロボットの制御,” 日本ロボット学会誌, vol.2, no.5, pp.480–486, 1984.
- [3] S. Schaal, “Learning from Demonstration,” Advances in Neural Information Processing Systems, vol.9, pp.1040–1046, MIT Press, 1996.
- [4] H. Ravichandar, A.S. Polydoros, S. Chernova, and A. Billard, “Recent Advances in Robot Learning from Demonstration,” Annual Review of Control, Robotics, and Autonomous Systems, vol.3, no.1, pp.297–330, 2020.
- [5] A. Ijspeert, J. Nakanishi, and S. Schaal, “Learning Attractor Landscapes for Learning Motor Primitives,” Advances in Neural Information Processing Systems, vol.15, pp.1545–1552, MIT Press, 2002.
- [6] S.M. Khansari-Zadeh and A. Billard, “Learning Stable Nonlinear Dynamical Systems With Gaussian Mixture Models,” IEEE Transactions on Robotics, vol.27, no.5, pp.943–957, Oct. 2011.
- [7] S. Arimoto, J.-H. Bae, H. Hashiguchi, and R. Ozawa, “Natural Resolution of Ill-Posedness of Inverse Kinematics for Redundant Robots Under Constraints,” Communications in Information and Systems, vol.4, no.1, pp.1–28, 2004.
- [8] M. Saveriano, F.J. Abu-Dakka, and V. Kyrki, “Learning stable robotic skills on Riemannian manifolds,” Robotics and Autonomous Systems, vol.169, p.104510, Nov. 2023.
- [9] W. Maass, T. Natschlager, and H. Markram, “Real-Time Computing Without Stable States: A New Framework for Neural Computation Based on Perturbations,” Neural Computation, vol.14, no.11, pp.2531–2560, Nov. 2002.
- [10] H. Jaeger, “The “echo state” approach to analysing and training recurrent neural networks – with an Erratum note,” Technical Report 148, German National Research Center for Information Technology, 2001.
- [11] H. Jaeger and H. Haas, “Harnessing Nonlinearity: Predicting Chaotic Systems and Saving Energy in Wireless Communication,” Science, vol.304, no.5667, pp.78–80, April 2004.
- [12] A. Hart, J. Hook, and J. Dawes, “Embedding and approximation theorems for echo state networks,” Neural Networks, vol.128, pp.234–247, Aug. 2020.
- [13] J.Z. Kim, Z. Lu, E. Nozari, G.J. Pappas, and D.S. Bassett, “Teaching recurrent neural networks to infer global temporal structure from local examples,” Nature Machine Intelligence, vol.3, no.4, pp.316–323, April 2021.